

Erweiterung des ETSi-Frameworks: Optimierung von Rekonstruktionsangriffen durch Genetische Algorithmen und Verhaltensbasierte Agenten

Muhammad Asher Khan

Ewin Wangler

Michail Gimpiliov

Bahadır Hacisalihoglu

Hussein Alameri

Abstract—Weltweit werden elektronische Mautsysteme (Electronic Toll Collection, ETC) zur Finanzierung von Infrastruktur und zur Beeinflussung von Verkehrsströmen eingesetzt. Da diese Systeme in der Regel verpflichtend sind und keine einfache Opt-out-Möglichkeit bieten, stellt der Schutz der Standortprivatsphäre der Nutzer eine zentrale Herausforderung dar. Zur systematischen Analyse von Rekonstruktionsangriffen auf solche Systeme wurde das Simulationsframework ETSi (Electronic Tolling Simulation Framework) entwickelt.

In dieser Arbeit geht es nicht nur um die grundsätzliche Frage, inwieweit physikalische Randbedingungen wie Reisezeiten und Netzstrukturen trotz datenschutzfreundlicher Mautsysteme sensible Standortinformationen preisgeben, sondern vor allem um eine ganzheitliche Erweiterung dieses Frameworks. Aufbauend auf ETSi analysiert dieses Projekt die Schwächen der bisherigen heuristischen Ansätze.

Um diese Limitationen zu überwinden, erweitern wir das Framework auf zwei Ebenen: Zum einen wird die Verkehrssimulation um diversifizierte, realitätsnahe Agentenprofile ergänzt, um eine authentischere Verkehrsnachfrage abzubilden. Zum anderen ersetzen wir die bisherige Heuristik durch einen global optimierenden, genetischen Algorithmus. Dieses evolutionsbasierte Verfahren bewertet Rekonstruktionshypothesen parallel und verbessert sie iterativ. Der Beitrag dieses Papers besteht aus (i) der Integration komplexer Verhaltensmodelle in die Simulation, (ii) der methodischen Implementierung genetischer Optimierung zur Trip- und Wallet-Rekonstruktion sowie (iii) einer detaillierten Evaluation, welche die Leistungssteigerung des neuen Ansatzes gegenüber den bisherigen Baselines belegt.

I. MOTIVATION UND PROBLEMSTELLUNG

Angesichts zunehmender Staus und Umweltbelastungen wachsen die Zweifel an der Nachhaltigkeit des heutigen Straßenverkehrs [1]. Um Infrastrukturkosten nach dem Verursacherprinzip (“user pays”) zu decken und das Verkehrsaufkommen gezielt zu steuern, setzen Behörden weltweit zunehmend auf elektronische Mautsysteme (Electronic Toll Collection, ETC) [1]. Diese Entwicklung birgt jedoch ein massives und stetig wachsendes Risiko für die Privatsphäre: Schätzungen zufolge wird allein der europäische ETC-Markt bis zum Jahr 2032 auf ein Volumen von 85 Milliarden Euro anwachsen und rund 120 Millionen Abonnenten umfassen [2]. Weltweit wird der Umsatz der ETC-Anbieter bis 2040 auf etwa 45,8 Mrd. USD steigen, mit einer durchschnittlichen jährlichen Wachstumsrate (CAGR) von

9,95% [3]. Dies bedeutet, dass in naher Zukunft ein Großteil der Bevölkerung von Maut-Infrastrukturen erfasst wird.

Verschärft wird diese Bedrohungslage durch einen rasanten technologischen Wandel. Neben klassischen Mikrowellentechnologien (DSRC) an festen Stationen geht der Trend stark in Richtung streckenübergreifender Multi-Lane Free Flow (MLFF)-Systeme sowie satelliten- (GNSS) und smart-phone-basierter Erfassung [2], [3]. Gleichzeitig treibt die Europäische Union durch die EETS-Richtlinie (European Electronic Toll Service) eine grenzüberschreitende Interoperabilität voran, die es Nutzern ermöglichen soll, mit nur einem Vertrag nahtlos durch verschiedene Länder zu reisen [1], [4]. Aus Sicht des Datenschutzes entsteht dadurch eine Infrastruktur zur umfassenden und länderübergreifenden Ortung von Fahrzeugen.

Da diese allgegenwärtigen Systeme eine kontinuierliche Erfassung voraussetzen und den Nutzern in der Regel keine Opt-out-Möglichkeit bieten, ist der Schutz personenbezogener Daten kritisch. Selbst die Europäische Kommission nennt den Datenschutz explizit als eine der zentralen Herausforderungen bei der Umsetzung solcher interoperablen Systeme:

“EETS provision requires to process large numbers of transactions with appropriate security mechanisms against data loss and corruption as well as data privacy breaches” [4].

Die anfallenden Standort-Zeit-Daten sind hochsensibel, da sie weitreichende Rückschlüsse auf Wohn- und Arbeitsorte, Tagesroutinen, soziale Kontakte sowie individuelle Gewohnheiten der Nutzer zulassen.

In der Forschung wurden als Gegenmaßnahme zahlreiche datenschutzfreundliche elektronische Mautsysteme (Privacy-Preserving ETC) vorgeschlagen. Diese verfolgen das Ziel, nur jene Informationen offenzulegen, die für die Abrechnung zwingend notwendig sind. Durch den Einsatz kryptografischer Verfahren (wie Zero-Knowledge-Beweise) soll der Dienstanbieter lediglich den Gesamtbetrag (das Wallet) einer Abrechnungsperiode verifizieren können, ohne zu erfahren, aus welchen konkreten Ortseignissen und Trips sich dieser Betrag zusammensetzt [5], [6].

Unklar bleibt jedoch, wie viel Information **trotz** solcher Schutzmechanismen durch langfristige Beobachtung und unter Berücksichtigung physikalischer Randbedingungen – insbesondere bekannter Reisezeiten und der Topologie des Straßennetzes – preisgegeben wird. Um diese Schwachstellen

systematisch aufzudecken, wurde das ETSi-Framework entwickelt. Damit stellt sich die Frage, inwieweit ein Angreifer, der lediglich über anonymisierte Fragmente verfügt, die Standortprivatsphäre der Nutzer kompromittieren kann. Ziel dieser Arbeit ist es, die bestehenden heuristischen Rekonstruktionsansätze von ETSi zu analysieren und zu zeigen, wie sich die Gefahr erfolgreicher De-Anonymisierung durch globale, evolutionsbasierte Optimierungsverfahren (Genetische Algorithmen) erhöht.

II. DER ETSI-ANSATZ: SIMULATIONSBASIERTE ANALYSE VON STANDORTPRIVATSPHÄRE

Um die Fragestellung systematisch untersuchen zu können, entwickelte die vorherige Projektgruppe den Simulationsrahmen ETSi (Electronic Tolling Simulation Framework). ETSi verfolgt einen experimentellen Ansatz: Anstatt reale Verkehrsdaten zu analysieren, werden künstliche, aber realistische Verkehrsszenarien erzeugt und anschließend gezielt angegriffen. Dadurch können zentrale Parameter wie Verkehrsdichte, Anzahl der Nutzer, Dauer der Beobachtung oder die Platzierung von Detektoren kontrolliert variiert werden. ETSi basiert auf der Verkehrssimulationssoftware SUMO (Simulation of Urban Mobility) und ist modular aufgebaut.

A. Verkehrsgenerator (Agents)

Der Verkehrsgenerator erzeugt synthetische Verkehrsnachfrage in Form von Agenten, die jeweils ein Fahrzeug repräsentieren. Jeder Agent besitzt ein Bewegungsprofil über mehrere Tage hinweg; in der ursprünglichen Implementierung werden insbesondere (Voll-/Teilzeit-) Arbeitsmuster modelliert. Start- und Zielorte werden innerhalb definierter Wohn- und Arbeitsdistrikte gewählt, die als Polygone im Kartennetz beschrieben sind. Aus dem Verhalten der Agenten entstehen konkrete Fahrten, die als Routen- und Trip-Dateien in SUMO eingespeist werden können.

B. Simulation

In der Simulationsphase wird die erzeugte Nachfrage in SUMO ausgeführt. Das Straßennetz enthält Road-Side Units (RSUs), die in ETSi als Detektoren realisiert werden. Jedes Passieren einer RSU erzeugt eine Transaktion. Intern liegen die vollständigen Informationen (Wallet/Trip/Zeit/Ort) vor; für die Analyse werden jedoch zwei unterschiedliche Wissensstände erzeugt:

- **Challenger Knowledge:** vollständige Ground-Truth-Daten inklusive Zuordnungen.
- **Attacker Knowledge:** anonymisierte Transaktionen sowie aggregierte Wallet Informationen (Gesamtschuld pro Nutzer), ohne direkte Zuordnung einzelner Transaktionen zu Nutzern.

C. Angreifer (Attacker)

Der Angreifer erhält ausschließlich das Attacker-Wissen. Seine Aufgabe besteht darin, anonymisierte Transaktionen wieder Nutzern bzw. rekonstruierten Trips zuzuordnen. Im ETSi-Paper werden u. a. ein Zufallsangriff sowie ein Trip-Rekonstruktionsangriff beschrieben; letzterer nutzt zusätz-

liche Informationen (z. B. Reisezeiten), um plausible Trips zu bilden und diese anschließend konsistent mit den Wallet-Summen zu kombinieren.

D. Challenger (Evaluation)

Der Challenger vergleicht das Angreiferergebnis mit der Ground Truth. Als Erfolgsmaß wird die Ähnlichkeit zwischen echten und rekonstruierten Wallets (bzw. Trips) über den Jaccard-Koeffizienten quantifiziert; das ETSi-Paper definiert daraus eine durchschnittliche maximale Ähnlichkeit über alle Wallets.

III. ERGEBNISSE UND STAND DES PROJEKTS NACH ABSCHLUSS DER VORHERIGEN PROJEKTGRUPPE

Die Evaluation des ETSi-Frameworks zeigt mehrere zentrale Erkenntnisse. Zufallsangriffe sind erwartungsgemäß kaum erfolgreich und verschlechtern sich mit steigender Nutzerzahl sowie längeren Beobachtungszeiträumen. Der heuristische Trip-Rekonstruktionsangriff (mit Simulated Annealing) erzielt im Vergleich dazu deutlich bessere Ergebnisse: Die Erfolgsraten bei der Rekonstruktion einzelner Trips liegen je nach Szenario im Bereich von 30–40%. Auch die Wallet-Zuordnung verbessert sich im Vergleich zum Zufallsangriff signifikant, bleibt jedoch absolut betrachtet mit Erfolgsraten von unter 11% eine enorme Herausforderung. Darüber hinaus werden Einschränkungen des bestehenden ETSi-Frameworks diskutiert, darunter (i) die begrenzte Vielfalt der Agentenmodelle, (ii) Teleportation-Effekte in SUMO als Artefakt Quelle sowie (iii) die stark heuristische, lokal entscheidende Struktur des Trip-Rekonstruktionsangriffs. Diese Aspekte beeinflussen Stabilität, Robustheit und Vergleichbarkeit über Szenarien hinweg.

IV. UNSERE IDEEN UND ANSÄTZE ZU BEGINN DES PROJEKTS

Zu Beginn des Projekts stand eine Einarbeitungsphase, in der das Projektteam den bestehenden ETSi-Framework-Ablauf, die Projektstruktur sowie die relevanten Codekomponenten analysierte. Ziel war es, den Simulationsablauf und die Angriffs- bzw. Evaluationsmechanismen nachvollziehbar zu verstehen und Schwachstellen des bisherigen Trip- und Wallet-Rekonstruktion systematisch zu identifizieren.

A. Verbesserung der Verkehrsgeneration (Agents)

Um die Komplexität und Realitätsnähe der synthetischen Verkehrsnachfrage zu erhöhen, wurde der Agenten-Generator im neuen System überarbeitet und flexibilisiert:

- **Diversifizierung der Agentenprofile:** Zu den klassischen Arbeitermustern wurden neue, dynamische Rollen hinzugefügt. Das Profil Homestay legt den Fokus beispielsweise auf Schulwege, regelmäßige Einkäufe und Freizeitaktivitäten. Das neu eingeführte Freelance-Profil erlaubt zudem sehr flexible Tagesabläufe, bei denen Aktivitäten mit einer definierten Wahrscheinlichkeit zu ganzen Trip-Ketten verbunden werden können, anstatt dass der Agent nach jedem Ziel isoliert nach Hause zurückkehrt.

- **Zentrale, dateibasierte Konfiguration:** Anstatt Wahrscheinlichkeiten und Dauern direkt in den Quellcode zu integrieren, nutzt der neue Ansatz eine zentrale YAML-Konfigurationsdatei (`agent_profiles.yaml`). Diese steuert nicht nur die prozentuale Zusammensetzung der gesamten Agentenpopulation, sondern parametrisiert auch Aufenthaltsdauern und Startzeiten. Die Logik unterstützt nun explizit statistische Verteilungen wie Gauß-Verteilungen (über Mittelwert und Standardabweichung)
- **Physikalische Berechnung von Wegzeiten:** Im alten System basierten die errechneten Abfahrtszeiten lediglich auf einem simplen, konstanten Geschwindigkeitsfaktor. Die neuen Agenten extrahieren nun die X- und Y-Koordinaten der Straßenkreuzungen (Junctions) aus der Karte. Daraus wird bei jedem Trip die euklidische Distanz berechnet. Um gleichzeitige Fahrten zu verhindern.
- **Komplexere Routenentscheidungen:** Die Routenfindung basiert nun auf modularen Teilaufgaben, die stochastisch eintreten können. Ein regulärer Worker kann beispielsweise abhängig von konfigurierten Wahrscheinlichkeiten auf dem Nachhauseweg einen Wocheneinkauf (grocery) einschieben oder weitere Besorgungen (errands) aus einem Pool an Zielen erledigen.

B. Analyse des bestehenden Angriffskonzepts

Die Analyse zeigte, dass der bestehende Rekonstruktionssangriff heuristisch geprägt ist und überwiegend lokale Entscheidungen trifft. Insbesondere die frühe Festlegung von Transaktionen auf Trips erschwert spätere Korrekturen und begünstigt eine Übersegmentierung, bei der rekonstruierte Fahrten häufig nur aus wenigen Transaktionen bestehen. Dies führt unweigerlich zu einem Dominoeffekt: Da die Wallet-Zuordnung auf diesen fehlerhaft segmentierten Trips aufbaut, vervielfältigen sich die lokalen Fehlentscheidungen bei der finalen Kostenzusammenführung. Diese Beobachtung entspricht den im ETSi-Paper beschriebenen Grenzen des bisherigen Ansatzes.

C. Zielsetzung unserer Weiterentwicklung

Auf Basis dieser Analyse wurde das Ziel formuliert, die Rekonstruktion von Trips und deren Zuweisung zu den finalen Wallets robuster, ganzheitlicher und konsistenter zu gestalten. Anstatt frühzeitig lokale Entscheidungen zu treffen, sollen alternative Zuordnungen über einen erweiterten Suchraum hinweg vergleichbar bewertet und iterativ verbessert werden. Der Fokus liegt dabei auf:

- Reduktion der Übersegmentierung von Trips
- Verbesserung der Rekonstruktion längerer, zusammenhängender Fahrten
- Globale Optimierung der Wallet-Zuordnung durch den Abgleich kombinierter Trip-Kosten mit den aggregierten Wallet-Summen
- Erhöhung der Stabilität gegenüber Simulations- und Detektorartefakten

- Einführung abgestufter Bewertungsmechanismen statt harter Ausschlusskriterien
- Verbesserung der Vergleichbarkeit alternativer Rekonstruktionslösungen

D. Einführung in genetische Algorithmen

Die bisherige heuristische Vorgehensweise ist lokal geprägt: Entscheidungen werden schrittweise und weitgehend unabhängig getroffen. Dadurch entstehen fragmentierte Trips, konkurrierende Zuordnungen einzelner Transaktionen sowie eine hohe Parameterabhängigkeit. In größeren Szenarien gewinnt dieses Problem an Bedeutung, da lokale Entscheidungen global bessere Lösungen blockieren können.

Dieses Verhalten ist in der zugrundeliegenden mathematischen Komplexität begründet. Wie bereits im ursprünglichen ETSi-Paper diskutiert wird, entspricht die exakte Zuordnung von anonymisierten Transaktionen zu Nutzern einer spezifischen Instanz des Rucksackproblems (Knapsack Problem) [5], [7]. Da dieses Problem NP-vollständig ist, lässt es sich für wachsende Netzwerke nicht mehr effizient exakt lösen. Die Autoren des ETSi-Papers merken jedoch an, dass solche Zuordnungen für realistische Szenarien ("real world instances") durch Annäherungsverfahren praktisch lösbar sein könnten [5], [7]. Vor diesem Hintergrund wurde ein Optimierungsverfahren gesucht, das den Rekonstruktionsprozess globaler betrachtet und mehrere plausible Lösungen parallel berücksichtigen kann. Genetische Algorithmen sind evolutionsbasierte Optimierungsverfahren, die insbesondere für solche stark kombinatorischen, NP-schweren Suchräume genutzt werden.

Grundprinzip

Anstelle der inkrementellen Verbesserung einer einzelnen Lösung wird eine Population von Kandidaten betrachtet. Jeder Kandidat repräsentiert eine vollständige Rekonstruktionszuweisung, etwa eine Zuordnung von Transaktionen zu Trip-IDs. Eine Fitness-Funktion aggregiert mehrere Qualitätskriterien zu einer skalaren Bewertungsgröße.

Evolutionmechanismus

Über Selektionsmechanismen sowie Variation (Mutation und Rekombination) entstehen neue Kandidaten, die erneut bewertet werden. Über mehrere Iterationen konvergiert die Population schrittweise zu Lösungen höherer Fitness.

Vorteile im Rekonstruktionskontext

Ein wesentlicher Vorteil liegt darin, dass mehrere konkurrierende Rekonstruktionshypothesen gleichzeitig existieren und gegeneinander evaluiert werden können. Dadurch wird die Optimierung weniger anfällig für frühe Fehlentscheidungen und das Steckenbleiben in lokalen Optima. Zudem erlaubt die Fitness-Funktion die gemeinsame Berücksichtigung unterschiedlicher Qualitätsaspekte – etwa der physikalischen und zeitlichen Konsistenz von Trips, sowie der Übereinstimmung der rekonstruierten Trip-Kosten mit den Wallet-Gesamtsummen.

E. Entscheidung für einen genetischen Optimierungsansatz

Zur Umsetzung der Ziele wird die Rekonstruktion als Optimierungsproblem modelliert. Kandidatenlösungen wer-

den über eine Fitness-Funktion bewertet und iterativ mithilfe genetischer Operatoren verbessert. Dies ermöglicht die Weiterentwicklung auch partiell inkonsistenter Zwischenlösungen, anstatt sie bei jeder Abwegigkeit frühzeitig auszuschließen.

F. Einfluss der Generationenanzahl auf die Lösungsfindung

Eine zentrale Herausforderung bei der Konfiguration genetischer Algorithmen ist die Bestimmung einer geeigneten Generationenanzahl, die den Kompromiss zwischen Rechenzeit und Lösungsqualität definiert. Ein Abbruch nach zu wenigen Iterationen birgt die Gefahr, dass der Algorithmus in einem lokalen Optimum konvergiert und das globale Optimum verfehlt. Demgegenüber steht ab einem gewissen Punkt ein abnehmender Grenznutzen (Diminishing Returns), bei dem zusätzliche Generationen erhebliche Rechenressourcen binden, ohne nennenswerte Verbesserungen der Fitness zu erzielen.




Fig. 1. Verlauf des Fitness-Scores über Generationen hinweg für verschiedene Agentenpopulationen während der Trip-Phase.




Fig. 2. Verlauf des Fitness-Scores über Generationen hinweg für verschiedene Agentenpopulationen während der Wallet-Phase.

Die Darstellung der Fitness-Evolution zeigt den typischen, stufenförmigen Konvergenzverlauf. Dabei lassen sich Phasen der Stagnation identifizieren, in denen die Population in lokalen Optima gefangen scheint. Ein markantes Beispiel zeigt sich bei der Trip-Phase mit 75 Agenten nahe der 2800. Generation. Die Tatsache, dass die Fitness nach dieser längeren Plateau-Phase wieder ansteigt, verdeutlicht die Wichtigkeit einer ausreichend hohen Generationenanzahl: Erst durch seltene, vorteilhafte Mutationen oder neue Crossover-Kombinationen konnte sich die Population aus diesem lokalen Optimum befreien.

G. Anpassung der Bewertungsfunktionen (Fitness)

Ein zentraler Bestandteil der Weiterentwicklung ist die Überarbeitung der Bewertungsfunktion. Harte Ausschlusskriterien können plausibel wirkende Rekonstruktionen bereits bei einzelnen Abweichungen vollständig eliminieren. Stattdessen werden abgestufte Straf- und Belohnungskomponenten eingesetzt, um unplausible Rekonstruktionen zu benachteiligen und gleichzeitig realistische Abweichungen (z. B. durch Artefakte) zu tolerieren.

Um die Parameter der Fitness-Funktionen optimal zu bestimmen, wurde eine systematische Hyperparameter-Optimierung mittels **Optuna** (Bayesian Optimization) durchgeführt. Da die Topologie des Straßennetzes sowie die Verkehrsdichte einen erheblichen Einfluss auf die Rekonstruktionsdynamik und das Auftreten von Artefakten haben, wurden die Parameter modellspezifisch abgestimmt. Konkret erfolgte das Training der Parameter getrennt für die jeweiligen Karten (Ingolstadt und Spider-Netz) sowie für unterschiedliche Verkehrsdichten, welche durch Szenarien mit 50 und 150 Agenten repräsentiert wurden. Dadurch wird sichergestellt, dass die Fitness-Funktion robust ist und optimal an die spezifischen räumlichen und kapazitiven Gegebenheiten des jeweiligen Szenarios angepasst ist.




Fig. 3. Vergleich der Simulationsumgebungen: Ingolstadt (links) und Spider-Netz (rechts)

H. Methodischer Ablauf

Der methodische Ablauf des genetischen Angriffs erfolgt in einem sequenziellen, zweistufigen Verfahren (erst Trip-, dann Wallet-Rekonstruktion) und lässt sich wie folgt zusammenfassen:

- 1) **Initiale Trip-Generierung:** Heuristische Erzeugung plausibler Basis-Trips aus den anonymisierten Roh-Transaktionen.
- 2) **Genetische Trip-Optimierung:** Abbildung der Zuordnung auf eine genetische Repräsentation (Transaktion → Trip-ID) und iterative Verbesserung der Fahrten unter Berücksichtigung physikalischer und zeitlicher Konsistenz.
- 3) **Initiale Wallet-Zuordnung:** Zuweisung der nun optimierten Trips zu potenziellen Nutzer-Wallets.
- 4) **Genetische Wallet-Optimierung:** Iterative Optimierung dieser Zuordnung (Trip → Wallet-ID) durch den präzisen Abgleich der aufsummierten Trip-Kosten mit den echten, aggregierten Wallet-Summen des Dienstanbieters.
- 5) **Evaluation:** Finale Bewertung der Rekonstruktionssqualität auf Trip- und Wallet-Ebene durch den Challenging (Abgleich mit der Ground Truth).

I. Erwartete Vorteile

Die Kombination aus Simulation, heuristischer Initialisierung und genetischer Optimierung zielt auf eine stabilere und konsistentere Rekonstruktion ab.

J. Anpassung der Bewertungsmetrik

Um die Qualität der Rekonstruktionsangriffe zu messen, verglich das ursprüngliche ETSi-Paper die vom Angreifer rekonstruierten Zuordnungen (A) mit den echten Zuordnungen der Ground Truth (C) auf Basis des Jaccard-Koeffizienten (Intersection over Union). Diese Metrik berechnet das Verhältnis von Schnittmenge zu Vereinigungsmenge beider Sets:

$$J(A, C) = \frac{|A \cap C|}{|A \cup C|} \quad (1)$$

Im Rahmen unserer methodischen Überarbeitung haben wir diese Metrik durch den F1-Score (mathematisch äquivalent zum Dice-Sørensen-Koeffizienten) ersetzt.

$$\text{Precision} = \frac{|A \cap C|}{|A|}, \quad \text{Recall} = \frac{|A \cap C|}{|C|} \quad (2)$$

Precision gibt an, wie viele der als positiv klassifizierten Elemente tatsächlich positiv sind, während **Recall** den Anteil der tatsächlich positiven Elemente beschreibt, die korrekt als positiv identifiziert wurden. Der F1-Score berechnet sich aus dem harmonischen Mittel dieser beiden Werte. Auf Mengenlehre angewandt, ergibt sich daraus exakt das Verhältnis der doppelten Schnittmenge zur Summe der Elemente beider Mengen:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 |A \cap C|}{|A| + |C|} \quad (3)$$

Diese Umstellung bietet für die Evaluation von Rekonstruktionsangriffen drei entscheidende Vorteile:

- **Bessere Balance bei Fragmentierung:** - **Fairere Bewertung bei Fragmentierung:** Der Jaccard-Koeffizient bestraft Zuordnungsfehler (fehlende oder zu viele Transaktionen) mathematisch extrem hart. Der F1-Score bewertet solche Teilübereinstimmungen deutlich ausgewogener. Dadurch entsteht gerade bei leicht ungenau rekonstruierten (über- oder untersegmentierten) Trips ein viel realistischeres Bild der tatsächlichen Leistung des Angreifers.
- **Intuitive Interpretierbarkeit:** Der F1-Score lässt sich direkt als prozentuales Maß für die korrekte Übereinstimmung lesen (ein Wert von 0.8 entspricht anschaulich einer 80%-igen Genauigkeit).
- **Wissenschaftliche Vergleichbarkeit:** Als Standardmetrik für Klassifikations- und Clustering-Probleme macht der F1-Score unsere Ergebnisse besser mit anderen Forschungsarbeiten vergleichbar.

V. EVALUATION

Verhalten von Scores je nach Agent Anzahl. Der Versuch wird so durchgeführt, dass wir für jeweils X Agents (25, 50, 75, 100, 150, 200, 300, 450, 600, 800, 1000) 3 Simulationsdatensätze mit verschiedenen Seeds erstellt. Wir führen die Angriffe 5-10 mal aus je nach Standardabweichung. Ziel ist

es eine niedrige Standardabweichung zu bekommen damit die Versuche reproduzierbar sind. Die Versuche werden auf zwei Karten (Ingolstadt & Spider) durchgeführt, und es wird der durchschnittliche F1-Score sowohl für die Trip-Zuordnung als auch für die Wallet-Zuordnung verglichen.

A. Versuchsaufbau und Methodik

Um die Leistungsfähigkeit und Robustheit des neu entwickelten genetischen Rekonstruktionsangriffs strukturiert zu bewerten, wurde eine umfassende Simulationsreihe durchgeführt. Das primäre Ziel dieser Evaluation ist es, das Verhalten der Rekonstruktionsqualität unter zunehmender Verkehrsdichte und Ambiguität zu analysieren.

Der Versuchsaufbau wird durch folgende Kernparameter definiert:

- **Untersuchte Netztopologien:** Die Experimente werden auf zwei topologisch grundverschiedenen Karten durchgeführt: einem synthetischen Spider-Netz (geometrisch homogen) sowie der Karte von Ingolstadt (realistisches, unregelmäßiges Straßennetz).
- **Skalierung der Verkehrsdichte:** Um den Einfluss der Auslastung auf die Fragmentierung von Trips zu messen, wird die Anzahl der simulierten Agenten schrittweise variiert (25, 50, 75, 100, 150, 200, 300, 450, 600, 800 und 1000 Agenten).
- **Datensätze und Randomisierung:** Um sicherzustellen, dass die Evaluationsergebnisse nicht das Resultat einer spezifischen, zufällig vorteilhaften Verkehrskonstellation sind, wurden für jede Agentenanzahl drei unabhängige Simulationsdatensätze mit unterschiedlichen Zufalls-Seeds generiert.
- **Statistische Signifikanz und Reproduzierbarkeit:** Da genetische Algorithmen stochastische Optimierungsverfahren sind, unterliegen die Ergebnisse einer natürlichen Varianz. Um diese auszugleichen, wird jeder Angriff pro Datensatz 5- bis 10-mal wiederholt. Die genaue Anzahl der Durchläufe wird dabei dynamisch an die beobachtete Standardabweichung gekoppelt.
- **Evaluationsmetriken:** Als primäres Vergleichsmaß dient der durchschnittliche F1-Score. Dieser wird getrennt evaluiert, um sowohl die Qualität der Trip-Zuordnung (korrekte Segmentierung der Fahrten) als auch die Präzision der finalen Wallet-Zuordnung (korrekte Kostenzusammenführung) zu beurteilen.

B. Versuch Ingolstadt




Fig. 4. Vergleich der F1-Scores für die Trip-Rekonstruktion auf dem Ingolstadt-Datensatz in Abhängigkeit der Agentenanzahl.




Fig. 5. Vergleich der F1-Scores für die Wallet-Zuordnung auf dem Ingolstadt-Datensatz in Abhängigkeit der Agentenanzahl.

Die Auswertung des Ingolstadt-Datensatzes liefert tiefe Einblicke in die Leistungsfähigkeit und Skalierbarkeit beider Algorithmen unter realistischen, asymmetrischen Netzbedingungen. Basierend auf den in Fig. 4, 5 dargestellten Verläufen lassen sich drei zentrale Beobachtungen ableiten:

1. Überlegenheit in der Trip-Rekonstruktion

Bei der Zuordnung einzelner Transaktionen zu Fahrten (Trip-F1-Score) zeigt sich, dass der genetische Algorithmus über alle Dichtestufen hinweg konstant bessere Ergebnisse liefert als der heuristische Ansatz. Besonders bei einer geringen bis mittleren Verkehrsdichte (25 bis 150 Agenten) kann die populationsbasierte Suche ihren Vorteil der globalen Optimierung voll ausspielen, da sie parallele Hypothesen bewertet und sich nicht in frühen Fehlentscheidungen verfängt. Mit zunehmender Agentenanzahl sinken erwartungsgemäß die Scores beider Algorithmen, da die Suchraumkomplexität exponentiell wächst; der genetische Ansatz behält jedoch stets die Oberhand.

2. Crossover-Effekt bei der Wallet-Zuordnung

Während der genetische Algorithmus bei kleinen Agentenanzahlen auch die Wallet-Zuordnung dominiert, ist ab einer Dichte von ca. 150 bis 200 Agenten ein interessanter Crossover-Effekt zu beobachten: Der "Advanced"-Algorithmus schneidet bei hochdichten Netzwerken in der Wallet-

Zuordnung leicht besser ab (z. B. 19.38% vs. 16.18% bei 1000 Agenten). Da der kombinatorische Suchraum für die Zuordnung von Trips mit steigender Agentenanzahl exponentiell wächst, ist es naheliegend, dass der genetische Algorithmus an die Skalierungsgrenzen seiner gewählten Hyperparameter stößt. Für derart große Netzwerke würde es daher eine noch spezifischere, auf Großnetze abgestimmte Parametrisierung erfordern, um das globale Optimum auf Wallet-Ebene zu erreichen.

3. Abnahme der Standardabweichung bei Skalierung

Darüber hinaus lässt sich in den Daten sehr gut erkennen, dass die Standardabweichung bei beiden Algorithmen kontinuierlich abnimmt, je mehr Agenten im System sind. Liegt die Standardabweichung bei 25 Agenten noch bei mehreren Prozentpunkten, konvergiert sie bei 1000 Agenten in den Promillebereich (z. B. $\pm 0.2\%$). Dieser Rückgang lässt sich primär durch statistische Mittelungseffekte (das Gesetz der großen Zahlen) erklären: In einem sehr kleinen Netzwerk (z. B. 25 Agenten) fällt eine einzelne "glückliche" oder falsche Entscheidung des Algorithmus an einer Kreuzung prozentual extrem stark ins Gewicht. In einem massiven Netzwerk mit 1000 Agenten und zehntausenden Transaktionen mitteln sich diese lokalen Glückstreffer und Fehler über die schiere Masse der Daten heraus. Der Suchraum wird so dicht und gleichmäßig komplex, dass die Algorithmen über verschiedene Runs und Seeds hinweg ein deterministisches und stabiles Leistungsniveau zeigen.

C. Versuch Spider




Fig. 6. Vergleich der F1-Scores für die Trip-Rekonstruktion auf dem Spider-Datensatz in Abhängigkeit der Agentenanzahl.




Fig. 7. Vergleich der F1-Scores für die Wallet-Zuordnung auf dem Spider-Datensatz in Abhängigkeit der Agentenanzahl.

Die Auswertung auf dem synthetischen Spider-Datensatz zeigt fundamentale Unterschiede in der Robustheit der beiden Algorithmen. Im Gegensatz zum realen Straßennetz von Ingolstadt zeichnet sich das künstliche Spider-Netzwerk durch eine hohe strukturelle Symmetrie aus. Dies führt zu unzähligen alternativen Routen mit nahezu identischen Kosten, was den Rekonstruktionsprozess massiv erschwert.

1. Visualisierung der Seed-Abhängigkeit

Bei der initialen Analyse der Daten zeigte der heuristische „Advanced“-Algorithmus eine extreme, unberechenbare Streuung der F1-Scores in Abhängigkeit vom gewählten Start-Seed. Aus diesem Grund wurde in der Visualisierung (siehe Fig. 6) bewusst darauf verzichtet, die Ergebnisse des heuristischen Ansatzes zu einem globalen Mittelwert mit zugehörigen Fehlerbalken zu aggregieren. Ein solcher aggregierter Min-Max-Bereich wäre so groß ausgefallen, dass er die eigentliche Dynamik und das tatsächliche Verhalten des Algorithmus völlig verschleiert hätte. Stattdessen werden die einzelnen Seeds für den heuristischen Algorithmus separat dargestellt.

2. Anfälligkeit für lokale Optima (Heuristisch)

Anhand der separaten Graphen lässt sich deutlich ablesen, dass die Leistung der lokalen Suche deterministisch vom initialen Zustand abhängt. Während bestimmte Seeds bei einer

Auslastung von 1000 Agenten noch F1-Scores von über 32% bei den Trips erreichen, stürzt die Rekonstruktionsqualität bei einem anderen Seed unter exakt denselben Rahmenbedingungen auf drastische 12.2% ab. Die Symmetrie des Netzes spannt hier ein Labyrinth aus lokalen Optima auf: Startet der Algorithmus in einem topologisch ungünstigen Zustand, nimmt er scheinbar optimale, in der Realität jedoch völlig falsche Pfade an und kann diese aufgrund seiner rein lokalen Arbeitsweise nicht mehr korrigieren.

3. Stabilität und Robustheit (Genetisch)

Im starken Kontrast dazu steht die Leistung des genetischen Algorithmus. Da die Ergebnisse dieses Ansatzes über alle verwendeten Seeds hinweg eine marginale Standardabweichung von oft nur $\pm 1\%$ bis $\pm 2\%$ aufwiesen, konnte dieser zur Wahrung der Übersichtlichkeit als klare, aggregierte Durchschnittslinie dargestellt werden. Der genetische Algorithmus zeigt sich immun gegen die symmetrischen Herausforderungen des Spider-Netzwerks. Durch die populationsbasierte, parallele Auswertung unzähliger Rekonstruktionshypothesen entgeht er der Gefahr lokaler Optima und liefert bis zur maximalen Netzwerkauslastung konstant stabile F1-Scores.

Dieser Versuch belegt eindrucksvoll den enormen Zugewinn an Stabilität und Reproduzierbarkeit, den evolutionäre Optimierungsverfahren in hochkomplexen, mehrdeutigen Suchräumen gegenüber klassischen Heuristiken bieten.

D. Reproduzierbarkeit der Ergebnisse

TABLE I
DURCHSCHNITTICHE STANDARDABWEICHUNG (σ) DER F1-SCORES.

Karte	Attacker	Seed	Trips σ (%)	Wallets σ (%)
Spider	Advanced	s1	0.26	0.66
		s2	0.24	0.54
		s3	0.17	0.52
	Genetic	s1	0.58	0.75
		s2	1.10	1.03
		s3	0.43	0.62
Ingolstadt	Advanced	s1	0.44	0.68
		s2	0.42	0.64
		s3	0.39	0.67
	Genetic	s1	0.76	0.95
		s2	0.60	0.92
		s3	0.81	0.90

Die vorliegende Tabelle zeigt die Stabilität und Reproduzierbarkeit der beiden Angreifer-Modelle („Advanced“ und „Genetic“) auf den untersuchten Datensätzen. Dargestellt ist die durchschnittliche Standardabweichung (σ) der F1-Scores für die Trip- und Wallet-Rekonstruktion über verschiedene Simulationen (Seeds: s1, s2, s3). Generell gilt: Je geringer die Standardabweichung, desto deterministischer und robuster

agiert der Algorithmus. Die Auswertung belegt für beide Ansätze eine hohe Zuverlässigkeit. Hervorzuheben ist, dass auch der „Genetic“-Attacker trotz seiner stochastischen, evolutionsbasierten Natur reproduzierbare Resultate liefert.

E. Erkenntnisse aus der Hyperparameter-Optimierung

Ein zentrales Ergebnis der Trainingsphase ist die Beobachtung, dass die optimalen Hyperparameter für die beiden untersuchten Netzwerke (Ingolstadt und Spider) divergieren. Das, obwohl in beiden Szenarien eine identische Verkehrsnachfrage (Agentenanzahl) simuliert wurde. Diese Diskrepanz lässt sich direkt auf die fundamental unterschiedliche Topologie und Skalierung der Netzwerke zurückführen:

1. Weitläufigkeit und physikalische Strafen

Ingolstadt ist ein weitläufiges, urbanes Straßennetz. Fehlerhafte Zuordnungen von Transaktionen über große geografische Distanzen erzeugen hier unverzüglich massive physikalische Unstimmigkeiten (z. B. unrealistische Geschwindigkeiten). Die Optimierungslogs bestätigen, dass der Algorithmus für Ingolstadt signifikant härtere Strafwerte gelernt hat: So fällt die Strafe für physikalische Unmöglichkeiten (teleportationPenalty) mit einem Wert von ca. 90.900 weitaus höher aus als im kompakteren Spider-Netz (ca. 66.600). Im Spider-Netz, in dem die Distanzen zwischen den Roadside Units (RSUs) geringer sind, greifen harte physikalische Ausschlusskriterien weniger präzise.

2. Asymmetrie und geografische Ankerpunkte

Reale Straßensysteme wie in Ingolstadt sind asymmetrisch und bündeln den Verkehr an natürlichen topologischen Engpässen (z. B. Brücken, Hauptachsen). Passagen durch diese Nadelöhre liefern spezifische, einzigartige Reisezeitprofile. Die Daten der Hyperparameter-Tuning-Phase belegen, dass der genetische Algorithmus lernt, diese Engpässe als „Ankerpunkte“ zu nutzen: Der Belohnungswert für das korrekte Matchen an Detektoren (detectorMatchBonus) wurde in Ingolstadt auf einen hohen Wert von 6.037 optimiert, während er im Spider-Netz bei lediglich 2.085 liegt. Da dem symmetrischen Spinnennetz solche natürlichen Engpässe fehlen und sich der Verkehr gleichmäßig verteilt, muss der Algorithmus die Routen anderweitig stabilisieren. Entsprechend wählte der Optimierer für das Spider-Netz einen höheren Exponenten zur Belohnung der Fahrtenlänge (tripLenExp: 0.80 vs. 0.75), um einer Fragmentierung der Fahrten entgegenzuwirken und Routen künstlich zusammenzuhalten.

3. Verzweigungsgrad und Ambiguität

Das künstliche Spider-Netz zeichnet sich durch einen enorm hohen Knotengrad aus: An fast jeder Kreuzung treffen symmetrische Straßen aufeinander, was den Agenten zahllose, exakt gleich lange und physikalisch fast identische Alternativrouten bietet. Für den genetischen Algorithmus erzeugt diese Symmetrie eine massive Ambiguität und hohe Verzweigungsgrade im Suchraum. Um nicht in scheinbar optimalen, in der Realität jedoch falschen Pfadkombinationen (lokalen Optima) stecken zu bleiben, benötigt der Algorithmus hier eine deutlich weichere, fehlertolerantere Justierung. In Ingolstadt ist die Varianz der sinnvollen Abzweigungen hingegen durch die natürliche Hierarchie der Straßenklassen

(Hauptverkehrsstraßen vs. Wohngebiete) stark limitiert. Es existiert für Strecken oft nur ein einziger „logischer“ Weg. Diese topologische Vorgabe reduziert den Suchraum erheblich und ermöglicht es dem genetischen Ansatz, fehlerhafte Kombinationen frühzeitig auszuschließen und schneller zu stabilen, globalen Rekonstruktionen zu konvergieren.

F. Prinzipbedingte Grenzen der Rekonstruktion (Limitierungen)

Die rein auf Metadaten basierende Rekonstruktion stößt bei zunehmender Verkehrsdichte an prinzipbedingte Grenzen.




Fig. 8. Typische Ambiguitätssituationen im SUMO-Verkehrsmodell: Fahrzeuge warten nebeneinander an einer Ampel (links) oder fahren parallel auf mehrspurigen Straßen (rechts).

Wie die Screenshots der SUMO-Simulationen verdeutlichen, kommt es im realen sowie simulierten städtischen Verkehr unweigerlich zu Parallelfahrten oder dem parallelen Warten an Ampeln. Generieren zwei oder mehr Agenten in exakt dieser Situation zeitgleich Transaktionen an derselben Roadside Unit (RSU), sind ihre digitalen Spuren für diesen Zeitraum identisch. Für den Angreifer entsteht eine deterministische Ununterscheidbarkeit. Es existiert schlichtweg kein mathematisches oder physikalisches Kriterium mehr, um zu entscheiden, welche Transaktion zu welchem Fahrzeug gehört. In dichten Szenarien (z. B. bei 1000 Agenten) häufen sich diese Situationen massiv, was den generellen Abfall der F1-Scores beider Algorithmen bei steigender Auslastung erklärt. Selbst ein theoretisch perfekter Optimierungsalgorithmus kann in solchen Momenten nur raten.

VI. DISKUSSION UND FAZIT

A. Implikationen für die Privatsphäre in elektronischen Mautsystemen

Die Ergebnisse dieser Arbeit liefern wichtige Grundlagen für die Risikobewertung im Umgang mit Mobilitätsdaten in zukünftigen Smart-City-Konzepten und insbesondere in interoperablen elektronischen Mautsystemen (ETC). Es konnte prinzipiell demonstriert werden, dass Pseudo-Anonymisierungsverfahren, wie das vollständige Entfernen der Zuordnungen von Transaktionen zu Nutzern, während lediglich die Gesamtsummen der Wallets bekannt bleiben, je nach Gegebenheiten keinen ausreichenden Schutz der Privatsphäre garantieren.

Besonders kritisch ist die Erkenntnis, dass gerade reale, organisch gewachsene Straßennetze (wie Ingolstadt) einem Angreifer methodisch in die Hände spielen. Die natürliche

Topologie zwingt Fahrer durch geografische Nadelöhre und erzeugt individuelle Reisezeitprofile. Mit Hilfe global optimierender Verfahren lassen sich diese Fragmente selbst aus unstrukturierten Datenmengen wieder zu Bewegungsprofilen zusammensetzen. Werden derartige Transaktions- und Abrechnungsdaten von Diensteanbietern unzureichend geschützt gespeichert, droht die De-Anonymisierung der Nutzer. Die dargelegte Methodik verdeutlicht, wie allein durch die Auswertung verpflichtender Maut-Metadaten unautorisierte Einblicke in Lebensgewohnheiten, Wohnorte und Arbeitsplätze möglich werden.

B. Ausblick und zukünftige Forschung

Obwohl das erweiterte Framework und der genetische Algorithmus bereits eine Stabilität aufweisen, besteht auf algorithmischer und infrastruktureller Ebene weiterhin Verbesserungspotenzial. Der genetische Algorithmus stößt bei sehr dichten, massiven Netzwerken an Skalierungsgrenzen. Zukünftige Forschungsarbeiten könnten den Ansatz daher weiterentwickeln, beispielsweise durch die dynamische Anpassung von Hyperparametern zur Laufzeit oder eine stärkere hybride Kopplung mit lokalen Suchverfahren. Da der heuristische “Advanced“-Ansatz bei der Wallet-Zuordnung in Großnetzen oft besser abschnit, bietet sich hier eine gezielte Kombination an: Ähnlich wie bei der Trip-Rekonstruktion, die bereits durch eine lokale Heuristik initialisiert und anschließend genetisch optimiert wird, könnte zukünftig auch die Wallet-Phase durch ein solches zweistufiges Verfahren verbessert werden.

Zudem kann die Stabilität des Frameworks generell weiter optimiert werden. Die verwendete Verkehrssimulation SUMO erweist sich bei massiven Datensätzen teils als instabil und rechenintensiv. Der Aufbau modernerer, vereinfachter Daten-Pipelines könnte den Workflow hier zukünftig deutlich beschleunigen und fehlerresistenter machen. Darüber hinaus erfordert auch die Agenten-Logik weiteren Feinschliff: Obwohl stark reduziert (meist unter 5%), treten bei sehr großen Datensätzen noch immer Simulationsartefakte auf, bei denen Agenten physikalisch unmögliche, zeitgleiche Trips generieren.

Ein weiterer essenzieller Ansatzpunkt für die zukünftige Forschung betrifft die Weiterentwicklung der Evaluationsmetrik. Wie zuvor dargelegt, führen Parallelfahrten oder das gemeinsame Warten an Ampeln zu einer deterministischen Ununterscheidbarkeit der digitalen Spuren. Das aktuelle Bewertungssystem straft Algorithmen ab, wenn sie in solchen Szenarien die exakten Transaktions-IDs von Fahrzeugen mit identischem zeitlichen Bewegungsprofil verwechseln. Aus Sicht eines realen Angreifers ist es im Kontext der Profilbildung jedoch völlig irrelevant, ob sich ein Zielfahrzeug auf der linken oder rechten Spur befand oder unmittelbar vor einem anderen fuhr. Solange die physisch zurückgelegte Route korrekt rekonstruiert wird, ist die Standortprivatsphäre kompromittiert.

Auf der Seite der Verteidigung unterstreicht diese Grundlagenarbeit die Dringlichkeit für den Einsatz stärkerer Privacy-Enhancing Technologies (PETs), um Nutzer in vernetzten Gebührensystemen effektiv zu schützen.

C. Fazit

Das primäre Ziel dieser Arbeit war es, die grundlegende Methodik von Rekonstruktionsangriffen auf elektronische Mautsysteme systematisch aufzuzeigen und die Schwächen bisheriger lokaler Heuristiken zu adressieren. Dies wurde durch eine ganzheitliche Erweiterung des ETSi-Frameworks erreicht. Neben der Integration komplexerer, verhaltensbasierter Agentenmodelle zur Erzeugung realistischer Verkehrsmuster umfasste diese Arbeit auch technische Code-Optimierungen und Fehlerbehebungen, die das zugrundeliegende Framework insgesamt robuster und praktikabler machen.

Die Evaluation zeigt, dass der neu eingeführte genetische Algorithmus eine wertvolle methodische Erweiterung darstellt. Er führt komplexe Rekonstruktionsangriffe auf Trip-Ebene robuster, reproduzierbarer und unabhängiger von lokalen Optima durch als der bisherige Ansatz. Gleichzeitig zeigt die Arbeit jedoch auch die Grenzen der evolutionsbasierten Optimierung auf: Der genetische Algorithmus schneidet nicht in jedem Bereich zwingend besser ab und unterliegt der lokalen Heuristik teils bei der exakten Kostenzuordnung (Wallets) in dichten Netzwerken.

Auch wenn sowohl das Simulations-Framework als auch der Optimierungsprozess Raum für zukünftige Verbesserungen bieten, wurde die prinzipielle Machbarkeit der De-Anonymisierung von Standortdaten durch Maut-Metadaten erfolgreich demonstriert. Die Gefahr der systematischen Profilbildung ist damit eine praktische Herausforderung, die bei der Gestaltung zukünftiger Mobilitätsinfrastrukturen zwingend berücksichtigt werden muss, um den Datenschutz in modernen Städten zu gewährleisten.

REFERENCES

- [1] European Commission, “Electronic Pricing and Payment,” *Mobility and Transport*, [Online]. Available: https://transport.ec.europa.eu/transport-themes/smart-mobility/road/application-areas/electronic-pricing-and-payment_en
- [2] PTOLEMUS Consulting Group, “Electronic Tolling Europe Study,” [Online]. Available: https://www.ptolemus.com/upcp_product/electronic-tolling-europe-study-2023-2/
- [3] Roots Analysis, “Electronic Toll Collection Market Overview,” [Online]. Available: <https://www.rootsanalysis.com/electronic-toll-collection-market>
- [4] Directorate-General for Mobility and Transport, European Electronic Toll Service, “The European Electronic Toll Service (EETS): 2011 Guide for the application of the directive on the interoperability of electronic road toll systems,” [Online]. Available: https://transport.ec.europa.eu/document/download/e5afc1a6-03f9-4933-aa6f-fae0a8e7d659_en?filename=2011-eets-european-electronic-toll-service_en.pdf
- [5] R. Deppe, H. Graßhoff, R. Kokorev, and T. Rohmund, “ETSi - An Electronic Tolling Simulation Framework for Attacking Location Privacy,” *Proceedings on Privacy Enhancing Technologies*, 2020.
- [6] A. Adavoudi Jolfaei, A. Boualouache, A. Rupp, S. Schiffner, and T. Engel, “A Survey on Privacy-Preserving Electronic Toll Collection Schemes for Intelligent Transportation Systems,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 24, no. 9, pp. 8945–8962, 2023, doi: 10.1109/TITS.2023.3266828.
- [7] M. Hoffmann, V. Fetzner, M. Nagel, A. Rupp, and R. Schwerdt, “P4TC – Provably-Secure yet Practical Privacy-Preserving Toll Collection,” *Proceedings on Privacy Enhancing Technologies*, no. 3, pp. 62–152, 2020, doi: 10.2478/popets-2020-0046.